

## Trabajo Práctico 1 - Panorámica:

I308 - Visión Artificial

Abril Diaco, Pilar Otero, Federico Pizarro Dal Maso

Nros. de legajo: 36763, 36584, 36389,  
adiaco@udesa.edu.ar, potero@udesa.edu.ar, fpizarrodalmaso@udesa.edu.ar

Segundo semestre 2026

### Resumen

El objetivo de esta práctica consiste en el análisis de imágenes y el reconocimiento de sus puntos principales, con la finalidad de desarrollar los algoritmos necesarios para la simulación de una imagen panorámica, construida a partir de las fotografías iniciales. Siguiendo esta línea, dados dos conjuntos de 3 imágenes provistos por la cátedra, uno de un cuadro y otro del Campus de la Universidad de San Andrés, se llevó a cabo un trabajo en el que, con las imágenes reducidas a un máximo de mil píxeles, se buscaron los denominados *keypoints* o puntos principales mediante el método SIFT y se disminuyó su cantidad mediante el algoritmo de Supresión No-Máxima Adaptativa. A continuación, se seleccionó la imagen central como ancla, seleccionada especialmente para reducir la cantidad de transformaciones a realizar. A partir de esto, se llevó a cabo la asociación de características entre cada una de las imágenes extremo con el ancla. Para ello, se implementaron dos tipos de estrategias: *Cross-Check* y *FLANN + Lowe Ratio*, aunque, el análisis de sus resultados llevó a la prueba de un tercer algoritmo combinado, el cual fue seleccionado para ambos conjuntos, como el modelo final al buscarse matches mas confiables, siendo estos un total de 56 y 125 para cada conjunto respectivamente, y presentar las menores distancias entre imágenes. Los resultados de la aplicación de RANSAC para la eliminación de los outliers y la estimación de las homografías dejaron en evidencia el poder de lo implementado, obteniéndose inliers que superan el 50 % del total para el caso del cuadro, y de mas del 77 % para las imágenes del Campus. A partir de los resultados obtenidos, fue posible completar el trabajo, juntando y mezclando las imágenes mediante *Stitching* y *Blending*, construyendo así, la panorámica final.

# 1. Introducción

La pregunta motivadora de este trabajo ronda en torno a cómo se puede reconocer una misma escena u objeto visto desde distintos ángulos para luego usar esa información para construir una imagen más amplia. En esta práctica, se busca experimentar dicho problema, construyendo una panorámica a partir de tres imágenes con zonas en común. Para unir las, se usó la imagen central como ancla y se transformaron las otras imágenes para alinearlas con ella.

La herramienta geométrica principal que se usó para hacer esta alineación es la denominada homografía, la cual se define como una transformación proyectiva entre dos planos: en lenguaje coloquial, permite relacionar puntos de una imagen con sus puntos correspondientes en otra. Esta transformación se representa con una matriz  $H$  de tamaño  $3 \times 3$  y se aplica sobre puntos escritos en coordenadas homogéneas:

$$\tilde{x}' \sim H\tilde{x}.$$

Aunque la matriz tiene nueve valores, en la práctica hay ocho valores independientes que determinar, ya que al multiplicarla por una constante no cambia la transformación que representa, por lo tanto la dividimos por el valor del noveno valor. Como cada par de puntos correspondientes aporta dos ecuaciones, se necesitan al menos cuatro pares de puntos para calcular una homografía.

Las homografías son útiles para hacer *stitching* dado que permiten llevar puntos de distintas imágenes a un mismo sistema de coordenadas. Si logramos estimar la homografía  $H$  que relaciona cada imagen lateral con la imagen ancla, podemos transformar las imágenes para que sus zonas en común se superpongan y formen una imagen más amplia, construyendo lo que se conoce como *panorámica*.

Para que esto funcione correctamente, se requieren las siguientes condiciones: la escena descrita por las imágenes a considerar debe ser plana, los objetos deben estar lo suficientemente lejos de la cámara y la cámara, al rotar, debe hacerlo aproximadamente desde un mismo centro de proyección. Bajo estas hipótesis, una **única** transformación puede explicar la relación geométrica entre ambas fotografías. En cambio, si estas condiciones no se cumplen, pueden aparecer deformaciones, bordes desalineados o regiones mal superpuestas.

En las imágenes provistas por la cátedra, estas condiciones no se cumplen en su totalidad, sino en algunas partes. En el conjunto del cuadro hay un plano principal muy claro: el mismo cuadro. Por eso, se espera que la homografía funcione mejor en esa zona. Sin embargo, otros elementos, como la mesa, están en planos y ángulos distintos, por lo que es esperable que no queden perfectamente alineados.

En el conjunto de imágenes del Campus de UdeSA, también se puede observar una estructura principal: el edificio. Si bien la escena presenta diversos elementos secundarios, como árboles, pasto y objetos del fondo, y profundidad; estos, gracias a la distancia desde la que fueron tomadas las fotografías terminan conformando el mismo plano, no dejando a simple vista las anomalías resultantes de la superposición.

## 2. Método

### Organización general

El método sigue un pipeline de procesamiento compuesto por varias etapas: a partir de las imágenes de entrada se detectan sus **puntos característicos** y su **descripción** a partir del algoritmo de SIFT (Scale-Invariant Feature Transform), seguido de la aplicación de la **Supresión de No Máxima Adaptativa** con el objetivo de quedarse únicamente con un subconjunto de los keypoints mejor distribuidos espacialmente. Luego, para cada par de imágenes (imagen lateral, imagen ancla), se repiten las etapas de **asociación de correspondencias** (implementando los algoritmos de *cross-check*, *Lowe Ratio* y un criterio combinado de ambos), **eliminación de outliers** mediante RANSAC (*RANdom SAmple Consensus*) para la detección de outliers y la **estimación de la homografía**, hasta finalmente **juntar y mezclar las imágenes** mediante *Stitching* y *Blending* en un único sistema de coordenadas, resultando en la panorámica final. En ambos conjuntos de datos (*cuadro* y *UdeSA*) se utilizó la imagen central (imagen 1) como ancla, dado que es la única que comparte zonas de solapamiento con las dos imágenes restantes, evitando así la necesidad de estimar una correspondencia directa entre las imágenes 0 y 2.

### Carga y preprocesamiento

Las imágenes de cada conjunto se cargaron originalmente a color utilizando el formato BGR, y se redujeron de tamaño a 1000 píxeles mediante la función `achicar`, dado que las fotografías originales alcanzaban resoluciones de hasta  $3072 \times 4096$  píxeles. Esta reducción posibilita que el procesamiento posterior sea considerablemente más liviano, evitando simultáneamente la pérdida de información relevante para el problema.

Adicionalmente, para la etapa de detección de características, las imágenes se convirtieron a escala de grises debido a que el algoritmo SIFT (*Scale-Invariant Feature Transform*) trabaja sobre gradientes de intensidad, construyendo una pirámide de diferencias de Gaussianas sobre una única señal de brillo. Frente a esta funcionalidad, el color en las imágenes solo encarecería el cómputo al trabajar sobre los canales rojo, verde y azul, en lugar de uno, sin la incorporación de nueva información.

**Detección y descripción con SIFT.** Sobre las imágenes en escala de grises se aplicó el detector SIFT (`cv2.SIFT_create`), que identifica puntos distintivos o keypoints a partir de extremos locales en un espacio de escala construido con diferencias de Gaussianas, y calcula para cada uno, un descriptor de 128 valores basado en histogramas de orientación del gradiente alrededor del punto. Esta construcción hace que los descriptores sean robustos frente a cambios moderados de escala, rotación e iluminación entre fotografías, condición necesaria dado que las tres imágenes de cada conjunto fueron tomadas desde ángulos y distancias ligeramente distintos.

**Supresión de No-Máxima Adaptativa (A-NMS).** Con el fin de evitar que los keypoints seleccionados se concentren en las zonas de mayor textura de cada imagen, se aplicó A-NMS sobre los keypoints detectados por SIFT. Para cada punto se calculó un radio de supresión, definido como la distancia al punto clave más cercano cuya respuesta fuera mayor, de modo que los puntos con mayor radio corresponden a máximos locales dominantes dentro de una región amplia de la imagen. Como resultado, los puntos retenidos quedan mejor distribuidos espacialmente en toda la imagen, lo cual resulta conveniente tanto para la calidad de la homografía estimada posteriormente como para acotar el costo computacional de las etapas de matching y RANSAC que se presentarán a continuación.

**Matching.** Para relacionar los keypoints entre cada imagen lateral (0 y 2) y la imagen ancla (1) se evaluaron tres estrategias de matching sobre los descriptores SIFT, usando en todos los casos distancia euclídea ( $L2$ ) por tratarse de descriptores de punto flotante. La estrategia de *cross-check* exige que dos keypoints sean mutuamente su mejor vecino en ambas direcciones. El *Lowe ratio* (umbral = 0,75), en cambio, descarta matches ambiguos comparando la distancia al primer y al segundo vecino más cercano. Finalmente, con el objetivo de ver los resultados de la combinación, se implementó un criterio combinado entre ambas estrategias que exige simultáneamente que el match supere el ratio de Lowe en ambas direcciones y que sea consistente bajo Cross-Check. Para la selección del método final, se priorizo la confiabilidad de las correspondencias por sobre la cantidad total de keypoints, dado que RANSAC requiere partir de un conjunto de matches con la menor proporción posible de outliers para converger a una buena homografía.

**Homografía manual con DLT.** Como complemento al método automático, se implementó el algoritmo DLT (*Direct Linear Transformation*) para estimar una homografía a partir de exactamente cuatro correspondencias elegidas manualmente con ayuda de una grilla de referencia. Este procedimiento se aplicó sobre el conjunto *cuadro*, donde la textura rica de la pintura permite identificar con precisión puntos físicos equivalentes en ambas imágenes (esquinas de figuras, extremos de trazos), repitiéndolo para los pares  $0 \rightarrow 1$  y  $2 \rightarrow 1$ . Al elegir los puntos se evitó que quedaran alineados entre sí y se buscó que estuvieran razonablemente distribuidos dentro de la zona de solapamiento, para que el sistema lineal resultante no quedara mal condicionado. A su vez, se validó cada homografía aplicándola con `cv2.warpPerspective` sobre la imagen completa, verificando visualmente que la región del cuadro quedara alineada con la imagen ancla.

**RANSAC.** Como los matches obtenidos con el criterio combinado todavía pueden incluir correspondencias incorrectas, se implementó RANSAC para estimar cada homografía de forma robusta. En cada una de las  $T = 2000$  iteraciones se seleccionaron cuatro correspondencias al azar, se calculó una homografía candidata con DLT, y se contó cuántas de todas las correspondencias disponibles resultaban *inliers* —con un error de reproyección menor a 5 píxeles—, conservando la iteración que maximizó esa cantidad. La homografía definitiva se recalculó luego por mínimos cuadrados (SVD) usando únicamente el conjunto de *inliers* ganador, en lugar de los cuatro puntos originales, para aprovechar toda la evidencia disponible en vez de depender de una muestra mínima.

**Warping, tamaño de canvas y panorámica final** Con las homografías finales de RANSAC, se calculó primero el tamaño óptimo del canvas donde se construiría cada panorámica: se transformaron las cuatro esquinas de cada imagen (ancla incluida) con su homografía correspondiente, y se tomaron los valores mínimos y máximos de esas coordenadas proyectadas para definir el ancho y alto necesarios. Como estas coordenadas pueden resultar negativas (dado que la esquina superior izquierda del canvas representa el  $(0,0)$ ), se agregó una traslación a cada homografía de forma que todo el contenido quede dentro del canvas. Sobre el mismo, cada imagen se transformó con `cv2.warpPerspective` usando su homografía ya ajustada, y en simultáneo se generó una máscara de peso a partir de `cv2.distanceTransform`, que asigna a cada píxel un valor proporcional a su distancia al borde más cercano de la imagen warpeada (elevado a la cuarta potencia, para que el peso decaiga más rápido cerca de los bordes y las costuras queden menos marcadas). El panorama final se obtuvo como un promedio ponderado píxel a píxel entre las imágenes superpuestas, usando esas máscaras como pesos  $W_i$  según  $I = \sum_i W_i I_i / \sum_i W_i$ , de modo que las zonas centrales de cada imagen, es decir, las más confiables, predominan sobre sus bordes en las regiones de solapamiento.

**Tamaño y formato de las imágenes.** Tanto las imágenes de entrada como las panorámicas resultantes se guardaron en formato `.jpg`. Las imágenes de entrada se redujeron a 1000 píxeles en su lado mayor antes de procesarlas (Sección *Carga y preprocesamiento*), y las panorámicas finales se exportaron con calidad JPEG 90, cumpliendo con el límite de tamaño por archivo sugerido en la consigna sin introducir artefactos de compresión perceptibles.

### 3. Resultados

#### Detección de keypoints y A-NMS


La cantidad de keypoints detectados por SIFT varió considerablemente entre conjuntos: en *cuadro* se hallaron entre 450 y 490 por imagen, mientras que en *UdeSA* se detectaron entre 2756 y 3120, reflejando la mayor cantidad de textura de alta frecuencia presente en la fachada del edificio, los árboles y el pasto, frente a las regiones de color más planas del cuadro. Sobre ese total se aplicó A-NMS, conservando una cantidad fija  $N$  por imagen: 200 para *cuadro* y 500 para *UdeSA*, valores elegidos en función de la cantidad inicial detectada en cada caso. La Figura 1 muestra el efecto sobre la imagen ancla de *cuadro*: los puntos retenidos quedan mejor distribuidos espacialmente en lugar de concentrarse en las zonas de mayor detalle.



**Figura 1:** Keypoints SIFT antes y después de aplicar A-NMS (imagen ancla, conjunto *cuadro*).

#### Matching

De las tres estrategias evaluadas, *cross-check* fue la que generó más correspondencias (84 y 74 para *cuadro*  $0 \rightarrow 1$  y  $2 \rightarrow 1$ ; 186 y 168 para *UdeSA*), mientras que el *Lowe ratio* produjo un conjunto más chico (52 y 34 para *cuadro*; 114 y 46 para *UdeSA*). El criterio combinado, exigiendo ambas condiciones simultáneamente, dio el conjunto más reducido pero con menor distancia media entre descriptores (40 y 16 correspondencias para *cuadro*; 93 y 32 para *UdeSA*), por lo que fue el elegido para las etapas siguientes. La Figura 2 compara, para *cuadro*, los matches sin filtrar contra los que sobreviven al criterio combinado.



**Figura 2:** Correspondencias sin filtrar (arriba) vs. criterio combinado (abajo), conjunto *cuadro*.

## Homografía manual (DLT)

Ambas homografías manuales re proyectan los cuatro puntos utilizados con error nulo (0.0000 px), lo cual es esperable dado que el sistema queda exactamente determinado por esos mismos cuatro pares y no constituye una medida de calidad sobre el resto de la imagen. Por eso se validó cada homografía aplicándola sobre la imagen completa (Figura 3), confirmando visualmente que la región del cuadro queda alineada con la imagen ancla.



**Figura 3:** Homografía manual (DLT) aplicada sobre la imagen completa, par 0  $\rightarrow$  1 de *cuadro*.

## RANSAC

Los resultados variaron entre pares de imágenes: en *cuadro* se obtuvo 77.5 % de inliers (31/40) con error de reproyección de 1.944 px para 0  $\rightarrow$  1, y 50 % de inliers (8/16) con error de 0.934 px para 2  $\rightarrow$  1; en *UdeSA* las proporciones de inliers fueron notablemente mayores, 96.8 % (90/93, error 0.980 px) y 78.1 % (25/32, error 1.424 px) respectivamente. La mayor proporción de outliers observada en *cuadro* 2  $\rightarrow$  1 es consistente con la menor cantidad de correspondencias combinadas disponibles en ese par (apenas 16), donde un puñado de matches erróneos pesa proporcionalmente más sobre el resultado. La Figura 4 muestra, para el par 0  $\rightarrow$  1 de cada conjunto, los inliers (verde) y outliers (rojo) detectados.



**Figura 4:** Inliers (verde) y outliers (rojo) tras RANSAC, par 0  $\rightarrow$  1: *cuadro* (izq.) y *UdeSA* (der.).

## Panorámica final


Con las homografías finales de RANSAC se construyeron las panorámicas de ambos conjuntos provistos (Figura 5), aplicando el cálculo de canvas óptimo y el blending por distancia descritos en la Sección de Método. En *UdeSA*, donde la escena se aproxima mejor a un plano único y las homografías tuvieron mayor proporción de inliers, la unión resulta prácticamente imperceptible. En *cuadro*, en cambio, se notan leves desalineaciones en la mesa y el borde inferior del cuadro, consistentes con que esos elementos no pertenecen exactamente al mismo plano que la superficie pintada usada para estimar la homografía.



**Figura 5:** Panorámicas finales: *cuadro* (izq.) y *UdeSA* (der.).

## Imágenes propias

Se aplicó el mismo pipeline completo sobre tres conjuntos propios tomados en la universidad (Figura 6): un ascensor, la biblioteca y una pecera. Los resultados de RANSAC fueron dispares: *pecera* obtuvo el mejor ajuste (100 % y 98.8 % de inliers, error de 0.68 y 0.87 px), *ascensor* un resultado intermedio (94.1 % y 99.2 % de inliers), y *biblioteca* el más débil (68.4 % y 70.8 % de inliers), consistente con una escena con mayor profundidad y más planos distintos entre sí.



**Figura 6:** Panorámicas de los conjuntos propios: ascensor, biblioteca y pecera.