

Trabajo Práctico 1 - Panorámica:

I308 - Vision Artificial

Abril Diaco, Pilar Otero, Federico Pizarro Dal Maso

Nros. de legajo: 36763, 36584, 36389,
adiaco@udesa.edu.ar, potero@udesa.edu.ar, fpizarrodalmaso@udesa.edu.ar

Segundo semestre 2026

Resumen

1. Introducción

La pregunta motivadora de este trabajo ronda en torno a cómo se puede reconocer una misma escena u objeto visto desde distintos ángulos para luego usar esa información para construir una imagen más amplia. En esta práctica, se busca experimentar dicho problema, construyendo una panorámica a partir de tres imágenes con zonas en común. Para unir las, se usó la imagen central como ancla y se transformaron las otras imágenes para alinearlas con ella.

La herramienta geométrica principal que usamos para hacer esta alineación es la homografía. Una homografía se define como una transformación proyectiva entre dos planos. En este contexto, nos permite relacionar puntos de una imagen con sus puntos correspondientes en otra. Esta transformación se representa con una matriz H de tamaño 3×3 y se aplica sobre puntos escritos en coordenadas homogéneas:

$$\tilde{x}' \sim H\tilde{x}.$$

Aunque la matriz tiene nueve valores, multiplicarla completa por una constante no cambia la transformación que representa. Por eso, en la práctica hay ocho valores independientes que determinar. Como cada par de puntos correspondientes aporta dos ecuaciones, se necesitan al menos cuatro pares de puntos para calcular una homografía.

Las homografías son útiles para hacer *stitching* porque permiten llevar puntos de distintas imágenes a un mismo sistema de coordenadas. Si logramos estimar la homografía que relaciona cada imagen lateral con la imagen ancla, podemos transformar las imágenes para que sus zonas en común se superpongan y formen una imagen más amplia.

Para que esto funcione bien, se necesitan ciertas condiciones. La homografía describe correctamente la relación entre dos imágenes cuando la escena es plana, cuando los objetos están lo suficientemente lejos de la cámara, o cuando la cámara rota aproximadamente desde un mismo centro de proyección. Bajo estas hipótesis, una única transformación puede explicar la relación geométrica entre ambas imágenes. En cambio, si estas condiciones no se cumplen, pueden aparecer deformaciones, bordes desalineados o regiones mal superpuestas.

En las imágenes provistas por la cátedra, estas condiciones se cumplen en algunas partes. En el conjunto del cuadro hay un plano principal muy claro: el mismo cuadro. Por eso, esperamos que la homografía funcione mejor en esa zona. Sin embargo, otros elementos, como la mesa, están en otros planos, por lo que pueden quedar desalineados.

En el conjunto de UdeSA también hay una estructura principal, que es el edificio. De todos modos, la escena tiene más elementos y más profundidad, como árboles, pasto y objetos del fondo. Por eso, una sola homografía puede no alcanzar para alinear toda la imagen, y es posible que este conjunto presente más errores.

Para construir la panorámica, entonces, organizamos el trabajo en varias etapas. Primero detectamos puntos característicos con SIFT y luego aplicamos A-NMS para quedarnos con puntos mejor distribuidos en la imagen. Después comparamos distintas formas de hacer matching, como **cross-check**, **Lowe Ratio** y un criterio

combinado. Con esas correspondencias, estimamos homografías: primero de forma manual usando DLT y luego de forma automática con RANSAC para descartar outliers. Finalmente, usamos las homografías obtenidas para transformar las imágenes y componer la panorámica final.

2. Método

Organización general

El método sigue un pipeline de procesamiento compuesto por varias etapas secuenciales: a partir de las imágenes de entrada se detectan sus **puntos característicos** y su **descripción**, seguido de la aplicación de la **Supresión de No Máxima Adaptativa** con el objetivo de quedarse únicamente con un subconjunto de puntos bien distribuidos espacialmente. Luego, para cada par de imágenes (imagen lateral, imagen ancla), se repiten las etapas de **asociación de correspondencias**, **eliminación de outliers mediante RANSAC** y **estimación de la homografía**, hasta finalmente **juntar y mezclar las imágenes** en un único sistema de coordenadas, resultando en la panorámica final. En ambos conjuntos de datos (*cuadro* y *UdeSA*) se utilizó la imagen central (imagen 1) como ancla, dado que es la única que comparte zonas de solapamiento con las dos imágenes restantes, evitando así tener que estimar una correspondencia directa entre las imágenes 0 y 2.

Carga y preprocesamiento

Las imágenes de cada conjunto se cargaron originalmente a color utilizando el formato BGR, y se redujeron de tamaño a 1000 píxeles mediante la función `achicar`, dado que las fotografías originales alcanzaban resoluciones de hasta 3072×4096 píxeles. Esta reducción posibilita que el procesamiento posterior sea considerablemente más liviano, evitando simultáneamente la pérdida de información relevante para el problema.

Adicionalmente, para la etapa de detección de características, las imágenes se convirtieron a escala de grises mediante debido a que el algoritmo SIFT (*Scale-Invariant Feature Transform*) trabaja sobre gradientes de intensidad — construye una pirámide de diferencias de Gaussianas sobre una única señal de brillo —. Frente a esta funcionalidad, el color en las imágenes solo encarecería el cómputo al trabajar sobre los canales rojo, verde y azul, en lugar de uno, sin la incorporación de nueva información.

Detección y descripción con SIFT.

Párrafo 3: Explicar que se usó SIFT para detectar keypoints y calcular descriptores. Los keypoints representan zonas distintivas de la imagen, como esquinas, bordes o cambios locales de textura. Los descriptores son vectores que resumen la información alrededor de cada keypoint y permiten comparar puntos entre imágenes.

Sobre las imágenes en escala de grises se aplicó el detector SIFT (`cv2.SIFT_create`), que identifica puntos distintivos —keypoints— a partir de extremos locales en un

espacio de escala construido con diferencias de Gaussianas, y calcula para cada uno un descriptor de 128 valores basado en histogramas de orientación del gradiente alrededor del punto. Esta construcción hace que los descriptores sean robustos frente a cambios moderados de escala, rotación e iluminación entre fotografías, condición necesaria dado que las tres imágenes de cada conjunto fueron tomadas desde ángulos y distancias ligeramente distintos. La cantidad de keypoints detectados varió considerablemente entre conjuntos: en *cuadro* se hallaron entre 450 y 490 keypoints por imagen, mientras que en *UdeSA* se detectaron entre 2756 y 3120, reflejando la mayor cantidad de textura de alta frecuencia presente en la fachada del edificio, los árboles y el pasto frente a las regiones de color más planas del cuadro.

A-NMS.

Párrafo 4: Explicar que se aplicó Supresión de No-Máxima Adaptativa para quedarse con una cantidad fija de puntos mejor distribuidos en la imagen. Esto evita que todos los keypoints se concentren en una sola zona con mucha textura.

Con el fin de evitar que los keypoints seleccionados se concentren en las zonas de mayor textura de cada imagen, se aplicó Supresión de No Máxima Adaptativa (A-NMS) sobre los keypoints detectados por SIFT. Para cada punto se calculó un radio de supresión, definido como la distancia al keypoint más cercano cuya respuesta fuera mayor, de modo que los puntos con mayor radio corresponden a máximos locales dominantes dentro de una región amplia de la imagen. Ordenando los keypoints por este radio de forma descendente, se conservó una cantidad fija N para cada imagen: 200 para el conjunto *cuadro* y 500 para *UdeSA*, valores elegidos en función de la cantidad inicial de keypoints detectados en cada caso. Como resultado, los puntos retenidos quedan mejor distribuidos espacialmente en toda la imagen, lo cual resulta conveniente tanto para la calidad de la homografía estimada posteriormente como para acotar el costo computacional de las etapas de matching y RANSAC.

Matching.

Párrafo 5: Explicar que se compararon los descriptores entre cada imagen lateral y la imagen ancla, es decir, entre las imágenes $0 \rightarrow 1$ y $2 \rightarrow 1$. Describir brevemente los métodos utilizados: cross-check, Lowe Ratio y el criterio combinado. Luego justificar que se eligió el criterio combinado porque prioriza matches más confiables antes de aplicar RANSAC.

Para relacionar los keypoints entre cada imagen lateral (0 y 2) y la imagen ancla (1) se evaluaron tres estrategias de matching sobre los descriptores SIFT, usando en todos los casos distancia euclídea (L_2) por tratarse de descriptores de punto flotante. La estrategia de *cross-check* exige que dos keypoints sean mutuamente su mejor vecino en ambas direcciones, y fue la que generó más correspondencias (84 y 74 para *cuadro* $0 \rightarrow 1$ y $2 \rightarrow 1$; 186 y 168 para *UdeSA*). El *Lowe ratio* (umbral = 0,75), en cambio, descarta matches ambiguos comparando la distancia al primer y al segundo vecino más cercano, y produjo un conjunto más chico (52 y 34 para *cuadro*; 114 y 46 para *UdeSA*). Finalmente, se implementó un criterio combinado que exige simultáneamente que el match supere el ratio de Lowe en ambas direcciones y que sea consistente bajo cross-check, obteniendo el conjunto más reducido pero también el de menor distancia media entre descriptores (40 y 16 correspondencias para *cuadro*; 93 y 32 para *UdeSA*). Se optó por este último criterio

para las etapas siguientes, priorizando la confiabilidad de las correspondencias por sobre la cantidad, dado que RANSAC requiere partir de un conjunto de matches con la menor proporción posible de outliers para converger a una buena homografía.

Homografía manual con DLT.

Párrafo 6: Explicar que se estimó una homografía manual usando cuatro pares de puntos correspondientes. Aclarar que esto se hizo sobre el conjunto del cuadro, donde era más sencillo identificar puntos sobre un mismo plano. Mencionar que DLT calcula una matriz que transforma puntos de una imagen al sistema de coordenadas de la imagen ancla.

Como complemento al método automático, se implementó el algoritmo DLT (*Direct Linear Transformation*) sin utilizar OpenCV, para estimar una homografía a partir de exactamente cuatro correspondencias elegidas manualmente con ayuda de una grilla de referencia. Este procedimiento se aplicó sobre el conjunto *cuadro*, donde la textura rica de la pintura permite identificar con precisión puntos físicos equivalentes en ambas imágenes (esquinas de figuras, extremos de trazos), repitiéndolo para los pares $0 \rightarrow 1$ y $2 \rightarrow 1$. Al elegir los puntos se evitó que quedaran alineados entre sí y se buscó que estuvieran razonablemente distribuidos dentro de la zona de solapamiento, para que el sistema lineal resultante no quedara mal condicionado. Ambas homografías reproyectan los cuatro puntos utilizados con error nulo (0.0000 px), lo cual es esperable dado que el sistema queda exactamente determinado por esos mismos cuatro pares y no constituye una medida de calidad sobre el resto de la imagen; por eso, además, se validó cada homografía aplicándola con `cv2.warpPerspective` sobre la imagen completa, verificando visualmente que la región del cuadro quedara alineada con la imagen ancla.

RANSAC.

Párrafo 7: Explicar que los matches automáticos pueden incluir errores, por lo que se usó RANSAC para separar inliers y outliers. En cada iteración, RANSAC elige cuatro matches, calcula una homografía con DLT, mide el error de reproyección y cuenta cuántos puntos son consistentes con esa transformación. Finalmente, se conserva la mejor homografía y se recalcula usando todos los inliers.

Como los matches obtenidos con el criterio combinado todavía pueden incluir correspondencias incorrectas, se implementó RANSAC sin utilizar OpenCV para estimar cada homografía de forma robusta. En cada una de las $T = 2000$ iteraciones se seleccionaron cuatro correspondencias al azar, se calculó una homografía candidata con DLT, y se contó cuántas de todas las correspondencias disponibles resultaban *inliers* —con un error de reproyección menor a 5 píxeles—, conservando la iteración que maximizó esa cantidad. La homografía definitiva se recalculó luego por mínimos cuadrados (SVD) usando únicamente el conjunto de inliers ganador, en lugar de los cuatro puntos originales, para aprovechar toda la evidencia disponible en vez de depender de una muestra mínima. Los resultados variaron entre pares de imágenes: en *cuadro* se obtuvo 77.5 % de inliers (31/40) con error de reproyección de 1.944 px para $0 \rightarrow 1$, y 50 % de inliers (8/16) con error de 0.934 px para $2 \rightarrow 1$; en *UdeSA* las proporciones de inliers fueron notablemente mayores, 96.8 % (90/93, error 0.980 px) y 78.1 % (25/32, error 1.424 px) respectivamente. La mayor proporción de outliers observada en *cuadro* $2 \rightarrow 1$ es consistente con la menor cantidad de correspon-

cias combinadas disponibles en ese par (apenas 16), donde un puñado de matches erróneos pesa proporcionalmente más sobre el resultado.

Warping, tamaño de canvas y panorámica final.

Párrafo 8: Explicar que, con las homografías finales, se transformaron las imágenes laterales para llevarlas al sistema de coordenadas de la imagen ancla. Luego se calculó el tamaño del canvas final para que entren todas las imágenes transformadas. Finalmente, se combinaron las imágenes para obtener la panorámica.

Con las homografías finales de RANSAC, se calculó primero el tamaño óptimo del canvas donde se construiría cada panorámica: se transformaron las cuatro esquinas de cada imagen (ancla incluida) con su homografía correspondiente, y se tomaron los valores mínimos y máximos de esas coordenadas proyectadas para definir el ancho y alto necesarios. Como estas coordenadas pueden resultar negativas, se agregó una traslación a cada homografía de forma que todo el contenido quede dentro del canvas. Sobre ese canvas, cada imagen se transformó con `cv2.warpPerspective` usando su homografía ya ajustada, y en simultáneo se generó una máscara de peso a partir de `cv2.distanceTransform`, que asigna a cada píxel un valor proporcional a su distancia al borde más cercano de la imagen warpeada (elevado a la cuarta potencia, para que el peso decaiga más rápido cerca de los bordes y las costuras queden menos marcadas). El panorama final se obtuvo como un promedio ponderado píxel a píxel entre las imágenes superpuestas, usando esas máscaras como pesos W_i según $I = \sum_i W_i I_i / \sum_i W_i$, de modo que las zonas centrales de cada imagen —más confiables— predominan sobre sus bordes en las regiones de solapamiento.

Tamaño y formato de las imágenes.

Párrafo 9: Aclarar que las imágenes fueron reducidas cuando fue necesario para que el procesamiento fuera más eficiente y para cumplir con el tamaño recomendado por la consigna.

Tanto las imágenes de entrada como las panorámicas resultantes se guardaron en formato `.jpg`. Las imágenes de entrada se redujeron a 1000 píxeles en su lado mayor antes de procesarlas (Sección *Carga y preprocesamiento*), y las panorámicas finales se exportaron con calidad JPEG 90, cumpliendo con el límite de tamaño por archivo sugerido en la consigna sin introducir artefactos de compresión perceptibles.

3. Resultados