

Trabajo Práctico 1 - Panorámica:

I308 - Visión Artificial

Abril Diaco, Pilar Otero, Federico Pizarro Dal Maso

Nros. de legajo: 36763, 36584, 36389,
adiaco@udesa.edu.ar, potero@udesa.edu.ar, fpizarrodalmaso@udesa.edu.ar

Segundo semestre 2026

Resumen

El objetivo de esta práctica fue analizar conjuntos de imágenes y reconocer puntos característicos entre ellas, con el fin de construir una imagen panorámica a partir de fotografías parcialmente solapadas. Para ello, se trabajó con dos conjuntos de tres imágenes provistos por la cátedra: uno correspondiente a un cuadro y otro al Campus de la Universidad de San Andrés. En ambos casos, las imágenes se redujeron a un máximo de mil píxeles en su lado mayor, se detectaron *keypoints* mediante SIFT y luego se aplicó Supresión No-Máxima Adaptativa para conservar un subconjunto de puntos mejor distribuido espacialmente.

A continuación, se tomó la imagen central como ancla, ya que comparte zonas de solapamiento con las dos imágenes laterales y permite reducir la cantidad de transformaciones necesarias. Sobre esta base, se realizó la asociación de características entre cada imagen lateral y el ancla. Se evaluaron las estrategias *cross-check* y *FLANN + Lowe Ratio*, y luego se implementó un criterio combinado entre ambas. Este último fue seleccionado para continuar con el trabajo, ya que produjo menos correspondencias, pero más confiables: 56 matches globales para *cuadro* y 125 para *UdeSA*, además de presentar las menores distancias medias entre descriptores.

Luego, se aplicó RANSAC para descartar outliers y estimar las homografías finales. Los resultados mostraron que, para el conjunto *cuadro*, los inliers alcanzaron el 77.5 % en el par $0 \rightarrow 1$ y el 50.0 % en el par $2 \rightarrow 1$, mientras que para *UdeSA* se obtuvieron porcentajes mayores, de 96.8 % y 78.1 % respectivamente. Finalmente, a partir de estas homografías, se realizó el *warping* de las imágenes hacia el sistema de coordenadas del ancla y se construyeron las panorámicas finales mediante *stitching* y *blending*. El mismo pipeline fue aplicado también sobre imágenes propias, permitiendo evaluar el método en escenas con distintas condiciones geométricas y niveles de profundidad.

1. Introducción

La pregunta motivadora de este trabajo ronda en torno a cómo se puede reconocer una misma escena u objeto visto desde distintos ángulos para luego usar esa información para construir una imagen más amplia. En esta práctica, se busca experimentar dicho problema, construyendo una panorámica a partir de tres imágenes con zonas en común. Para unir las, se usó la imagen central como ancla y se transformaron las otras imágenes para alinearlas con ella.

La herramienta geométrica principal que se usó para hacer esta alineación es la denominada homografía, la cual se define como una transformación proyectiva entre dos planos: en lenguaje coloquial, permite relacionar puntos de una imagen con sus puntos correspondientes en otra. Esta transformación se representa con una matriz H de tamaño 3×3 y se aplica sobre puntos escritos en coordenadas homogéneas:

$$\tilde{x}' \sim H\tilde{x}.$$

Aunque la matriz tiene nueve valores, en la práctica hay ocho valores independientes que determinar, ya que al multiplicarla por una constante no cambia la transformación que representa, por lo tanto la dividimos por el valor del noveno valor. Como cada par de puntos correspondientes aporta dos ecuaciones, se necesitan al menos cuatro pares de puntos para calcular una homografía.

Las homografías son útiles para hacer *stitching* dado que permiten llevar puntos de distintas imágenes a un mismo sistema de coordenadas. Si logramos estimar la homografía H que relaciona cada imagen lateral con la imagen ancla, podemos transformar las imágenes para que sus zonas en común se superpongan y formen una imagen más amplia, construyendo lo que se conoce como *panorámica*.

Para que esto funcione correctamente, se requieren las siguientes condiciones: la escena descrita por las imágenes a considerar debe ser plana, los objetos deben estar lo suficientemente lejos de la cámara y la cámara, al rotar, debe hacerlo aproximadamente desde un mismo centro de proyección. Bajo estas hipótesis, una **única** transformación puede explicar la relación geométrica entre ambas fotografías. En cambio, si estas condiciones no se cumplen, pueden aparecer deformaciones, bordes desalineados o regiones mal superpuestas.

En las imágenes provistas por la cátedra, estas condiciones no se cumplen en su totalidad, sino solo en algunas partes. En el conjunto del cuadro hay un plano principal muy claro: el mismo cuadro. Por eso, se espera que la homografía funcione mejor en esa zona. Sin embargo, otros elementos, como la mesa, están en planos y ángulos distintos, por lo que es esperable que no queden perfectamente alineados.

En el conjunto de imágenes del Campus de UdeSA también se observa una estructura principal: el edificio. Si bien la escena presenta elementos secundarios, como árboles, pasto y objetos del fondo, estos se encuentran relativamente lejos de la cámara. Por eso, aunque no pertenecen exactamente al mismo plano, las diferencias de profundidad generan efectos menos visibles. En consecuencia, se espera que las desalineaciones por superposición sean menos notorias a simple vista.

2. Método

El método siguió un pipeline de procesamiento compuesto por varias etapas. A partir de las imágenes de entrada, primero se detectaron puntos característicos y se calcularon sus descriptores usando SIFT. Luego, se aplicó Supresión de No Máxima Adaptativa con el objetivo de quedarnos con un subconjunto de keypoints mejor distribuidos espacialmente.

Después, para cada par de imágenes formado por una imagen lateral y la imagen ancla, se realizó la asociación de correspondencias. Para esto, se compararon tres criterios de matching: *cross-check*, *Lowe Ratio* y un criterio combinado que utilizó ambos. A partir de las correspondencias elegidas, se aplicó RANSAC para descartar outliers y estimar la homografía entre cada imagen lateral y la imagen ancla. Finalmente, las imágenes se transformaron a un mismo sistema de coordenadas y se combinaron mediante *stitching* y *blending* para obtener la panorámica final.

En ambos conjuntos de datos, *cuadro* y *UdeSA*, se utilizó la imagen central, es decir la imagen 1, como ancla. Esta decisión se debió a que es la única que compartía zonas de solapamiento con las dos imágenes restantes, evitando así la necesidad de estimar una correspondencia directa entre las imágenes 0 y 2.

Preprocesamiento de las imágenes

Las imágenes de cada conjunto se cargaron originalmente a color utilizando el formato BGR, y se redujeron de tamaño a 1000 píxeles mediante la función `achicar`, dado que las fotografías originales alcanzaban resoluciones de hasta 3072×4096 píxeles. Esta reducción posibilita que el procesamiento posterior sea considerablemente más liviano, evitando además la pérdida de información relevante.

Adicionalmente, para la etapa de detección de características, las imágenes se convirtieron a escala de grises. Esto se debe a que SIFT trabaja sobre cambios de intensidad, es decir, sobre una única señal de brillo. En particular, el algoritmo construye una pirámide de diferencias de Gaussianas y detecta puntos característicos a partir de variaciones locales en esa intensidad. Por este motivo, usar la imagen en color no aportaba información necesaria para esta etapa y solo aumentaba el costo computacional, ya que implicaría procesar tres canales en lugar de uno.

Detección y selección de puntos característicos

Sobre las imágenes en escala de grises se aplicó el detector SIFT (`cv2.SIFT_create`). Este método permite identificar puntos característicos o keypoints en zonas relevantes de la imagen, como bordes, esquinas o regiones con cambios de intensidad. Para cada uno de estos puntos, SIFT calcula un descriptor numérico que resume la información local alrededor del punto, principalmente a partir de la orientación de los gradientes. Esto permite comparar puntos entre distintas imágenes aun cuando existan cambios moderados de escala, rotación o iluminación, lo cual resulta importante dado que las tres imágenes de cada conjunto fueron tomadas desde ángulos y distancias ligeramente distintos.

Con el fin de evitar que los keypoints seleccionados se concentren en las zonas de mayor textura de cada imagen, se aplicó A-NMS sobre los keypoints detectados por SIFT. La idea fue asignarle a cada punto i un radio de supresión ρ_i , que mide qué tan lejos está del keypoint más cercano con una respuesta mayor. En nuestro caso, se calculó como:

$$\rho_i = \min_{j: \text{response}_j > \text{response}_i} \|x_i - x_j\|_2^2.$$

En esta expresión, x_i representa la posición del keypoint i en la imagen, response_i es la respuesta asignada por SIFT a ese punto, y j recorre todos los keypoints que tienen una respuesta mayor que la de i . Por lo tanto, ρ_i queda definido como la distancia cuadrada al punto más cercano que sea más

fuerte. Si un keypoint tiene un valor alto de ρ_i , significa que no tiene cerca otro punto con mayor respuesta, por lo que representa un máximo local dominante en una región amplia de la imagen.

Finalmente, se conservaron los keypoints con mayor valor de ρ_i . De esta manera, los puntos retenidos quedaron mejor distribuidos espacialmente, lo cual resulta conveniente tanto para la calidad de la homografía estimada posteriormente como para acotar el costo computacional de las etapas de matching y RANSAC.

Matching y selección de correspondencias

Para relacionar los keypoints entre cada imagen lateral (0 y 2) y la imagen ancla (1), se evaluaron tres estrategias de matching sobre los descriptores SIFT. En todos los casos se utilizó distancia euclídea (L_2), dado que los descriptores de SIFT son vectores de punto flotante.

La estrategia de *cross-check* exige que dos keypoints sean mutuamente su mejor vecino en ambas direcciones. Es decir, un punto de la primera imagen debe elegir como mejor candidato a un punto de la segunda, y ese mismo punto debe elegirlo también como mejor candidato en el sentido inverso.

Por otro lado, el criterio de *Lowe Ratio* busca descartar correspondencias ambiguas. Para esto, compara la distancia al mejor vecino, d_1 , con la distancia al segundo mejor vecino, d_2 , y conserva el match solo si se cumple:

$$d_1 < 0,75 d_2.$$

De esta manera, se conservan correspondencias donde el mejor candidato se diferencia claramente del segundo mejor. Finalmente, se implementó un criterio combinado entre ambas estrategias, que exige simultáneamente que el match supere el ratio de Lowe en ambas direcciones y que además sea consistente bajo *cross-check*.

Para la selección del método final, se priorizó la confiabilidad de las correspondencias por sobre la cantidad total de matches, dado que RANSAC requiere partir de un conjunto de correspondencias con la menor proporción posible de outliers para estimar una buena homografía.

Estimación de homografías

Como complemento al método automático, se implementó el algoritmo DLT (*Direct Linear Transformation*) para estimar una homografía a partir de cuatro correspondencias elegidas manualmente con ayuda de una grilla de referencia. Este procedimiento se aplicó sobre el conjunto *cuadro*, donde la textura de la pintura permite identificar con precisión puntos físicos equivalentes en ambas imágenes, como bordes y extremos de trazos, repitiéndolo para los pares $0 \rightarrow 1$ y $2 \rightarrow 1$. Al elegir los puntos se evitó que quedaran alineados entre sí y se buscó que estuvieran razonablemente distribuidos dentro de la zona de solapamiento, para que el sistema lineal resultante no quedara mal condicionado. A su vez, se validó cada homografía aplicándola con `cv2.warpPerspective` sobre la imagen completa, verificando visualmente que la región del cuadro quedara alineada con la imagen ancla.

Como los matches obtenidos con el criterio combinado todavía pueden incluir correspondencias incorrectas, se implementó RANSAC para estimar cada homografía de forma robusta. En cada una de las $T = 2000$ iteraciones se seleccionaron cuatro correspondencias al azar, se calculó una homografía candidata con DLT, y se evaluó qué tan bien esa transformación explicaba el conjunto completo de matches. Para esto, se calculó el error de reproyección entre cada punto proyectado y su correspondencia esperada:

$$e_i = \|x'_i - \hat{x}_i\|_2,$$

donde x'_i es el punto x_i transformado por la homografía candidata, y $\hat{x}_i$ es el punto correspondiente en la imagen ancla. Una correspondencia se consideró *inlier* cuando este error fue menor a 5 píxeles. Finalmente, se conservó la iteración con mayor cantidad de inliers.

Luego, se recalculó la homografía usando todas esas correspondencias. Como en este caso hay más de cuatro pares de puntos, el sistema queda sobredeterminado y no se busca una solución exacta, sino una que minimice el error algebraico. Para esto se arma un sistema homogéneo de la forma $Ah \approx 0$, donde h contiene los parámetros de la homografía.

Como la solución trivial $h = 0$ no representa una homografía válida, se impone la restricción $\|h\|_2 = 1$. Así, el problema se puede escribir como:

$$\min_{\|h\|_2=1} \|Ah\|.$$

Este problema se resuelve mediante la descomposición SVD de A . La solución corresponde a la dirección en la que Ah tiene menor norma, es decir, al vector singular asociado al menor valor singular. En la implementación, este vector se obtiene como la última fila de V^T , se reorganiza como una matriz 3×3 y se normaliza para obtener la homografía final.

Warping, blending y construcción de la panorámica

Con las homografías finales de RANSAC, se calculó primero el tamaño del canvas donde se construiría cada panorámica. Para esto, se transformaron las cuatro esquinas de cada imagen, incluida la imagen ancla, usando su homografía correspondiente. En este contexto, transformar o *warp*ear una imagen significa aplicar una transformación geométrica a sus píxeles para llevarlos a un nuevo sistema de coordenadas. En nuestro caso, ese sistema fue el de la imagen ancla.

Luego, se tomaron los valores mínimos y máximos de las esquinas transformadas para definir el ancho y alto necesarios. Como algunas coordenadas podían resultar negativas, se agregó una traslación a cada homografía. Si las coordenadas mínimas eran $x_{\min}$ e $y_{\min}$, la traslación aplicada fue $(-x_{\min}, -y_{\min})$, de forma que todo el contenido quedara dentro del canvas final. Una vez definido este sistema común de coordenadas, cada imagen se transformó mediante `cv2.warpPerspective` usando su homografía ajustada.

Para combinar las imágenes transformadas, se construyó una máscara de peso para cada una usando `cv2.distanceTransform`. Esta máscara asigna a cada píxel un peso proporcional a su distancia al borde más cercano de la imagen warpeada, de modo que las zonas centrales tienen mayor peso que los bordes. En nuestra implementación, estos pesos se elevaron a la cuarta potencia para que el peso decayera más rápido cerca de los bordes y las costuras fueran menos visibles. Finalmente, la panorámica se obtuvo como un promedio ponderado píxel a píxel entre las imágenes superpuestas:

$$I = \frac{\sum_i W_i I_i}{\sum_i W_i},$$

donde I_i representa cada imagen transformada y W_i su máscara de pesos correspondiente. De esta manera, en las regiones de solapamiento predominan las zonas centrales de cada imagen, que suelen ser más confiables que los bordes.

Formato de salida

Tanto las imágenes de entrada como las panorámicas resultantes se guardaron en formato `.jpg`, donde las panorámicas finales se exportaron con calidad JPEG 90. Además, para no perder calidad visual en el resultado final, algunas panorámicas se reconstruyeron también en alta resolución. Para esto, no se repitió todo el pipeline sobre las imágenes originales, sino que se reescalaron las homografías estimadas sobre las imágenes reducidas y luego se aplicaron sobre las fotografías originales.

3. Resultados

Detección de keypoints y A-NMS

La cantidad de keypoints detectados por SIFT varió considerablemente entre conjuntos. En *cuadro* se detectaron 481, 450 y 490 keypoints en las imágenes 0, 1 y 2 respectivamente, mientras que en *UdeSA* se obtuvieron 3118, 3038 y 2756. Esta diferencia es consistente con el contenido de cada escena: el conjunto *UdeSA* presenta más textura de alta frecuencia en la fachada del edificio, los árboles y el pasto, mientras que el conjunto *cuadro* contiene regiones más planas y uniformes.

Luego de aplicar A-NMS, se conservó una cantidad fija de puntos por imagen: 200 para *cuadro* y 500 para *UdeSA*. Estos valores fueron elegidos en función de la cantidad inicial de keypoints detectados en cada conjunto. Como se observa en Figura 1, el filtrado permitió retener puntos mejor distribuidos espacialmente, en lugar de concentrarlos únicamente en las zonas de mayor detalle.



Figura 1: Keypoints detectados por SIFT antes y después de aplicar A-NMS en la imagen ancla de *cuadro* (izq.) y *UdeSA* (der.). Luego del filtrado, los puntos quedan mejor distribuidos espacialmente.

Matching

Al comparar las estrategias de matching, *cross-check* fue la que generó más correspondencias: 84 y 74 para *cuadro* en los pares $0 \rightarrow 1$ y $2 \rightarrow 1$, y 186 y 168 para *UdeSA*. En cambio, *FLANN + Lowe ratio* produjo conjuntos más reducidos: 52 y 33 correspondencias para *cuadro*, y 114 y 45 para *UdeSA*.

El criterio combinado fue el más restrictivo, ya que exigió simultáneamente baja ambigüedad y consistencia ida y vuelta. Por eso, produjo menos correspondencias: 40 y 16 para *cuadro*, y 93 y 32 para *UdeSA*. Sin embargo, como se resume en Tabla 1, también presentó una menor distancia media global entre descriptores. En *cuadro*, la distancia media bajó de 227.07 con *cross-check* y 168.19 con *FLANN + Lowe* a 162.86 con el criterio combinado. En *UdeSA*, bajó de 207.62 y 127.89 a 111.77. Por este motivo, se eligió el criterio combinado para las etapas siguientes.

Conjunto y método	Matches	Distancia media	Distancia mediana
<i>Cuadro</i> - Cross-check	158	227.07	221.08
<i>Cuadro</i> - FLANN + Lowe	86	168.19	169.37
<i>Cuadro</i> - Combinado	56	162.86	159.21
<i>UdeSA</i> - Cross-check	354	207.62	223.74
<i>UdeSA</i> - FLANN + Lowe	158	127.89	119.13
<i>UdeSA</i> - Combinado	125	111.77	104.19

Cuadro 1: Comparación global de las estrategias de matching. El criterio combinado conserva menos correspondencias, pero reduce la distancia media entre descriptores.

La comparación visual de la Figura 2 muestra esta diferencia para el conjunto *cuadro*: al pasar de matches sin filtrar al criterio combinado, se descartan muchas correspondencias ambiguas o poco consistentes.




Figura 2: Comparación entre correspondencias sin filtrar y correspondencias retenidas por el criterio combinado en el conjunto *cuadro*. El filtrado reduce matches ambiguos y conserva asociaciones más consistentes.

Homografía manual

Las homografías manuales estimadas con DLT reprojectaron los cuatro puntos utilizados con error nulo, es decir, 0,0000 px. Esto era esperable, ya que la homografía fue calculada exactamente a partir de esos mismos cuatro pares de puntos. Por este motivo, ese error no alcanza para evaluar la calidad de la transformación sobre toda la imagen.

Para validar el resultado de manera más informativa, se aplicó cada homografía sobre la imagen completa. En Figura 3 se observa que la región del cuadro queda razonablemente alineada con la imagen ancla, especialmente sobre la zona plana de la pintura. Las diferencias restantes aparecen principalmente en regiones que no pertenecen al mismo plano, como la mesa o partes del entorno.




Figura 3: Homografía manual estimada con DLT y aplicada sobre la imagen completa para el par $0 \rightarrow 1$ del conjunto *cuadro*. La alineación se observa principalmente sobre el plano del cuadro.

RANSAC

Los resultados de RANSAC variaron entre pares de imágenes. En *cuadro*, para el par $0 \rightarrow 1$ se obtuvo un 77.5 % de inliers, con 31 correspondencias aceptadas sobre 40 y un error de reproyección de 1.944 px. Para el par $2 \rightarrow 1$, la proporción bajó a 50.0 %, con 8 inliers sobre 16 y un error de 0.934 px.

En *UdeSA*, las proporciones de inliers fueron mayores: 96.8 % para $0 \rightarrow 1$, con 90 inliers sobre 93 y un error de 0.980 px, y 78.1 % para $2 \rightarrow 1$, con 25 inliers sobre 32 y un error de 1.424 px. Esto indica que, en este conjunto, las correspondencias automáticas fueron más consistentes con una única homografía.

El caso más débil fue *cuadro 2* $\rightarrow$ 1, donde había pocas correspondencias combinadas disponibles. En ese contexto, unos pocos matches incorrectos tienen más peso sobre el resultado final. Además, el menor error de reproyección en ese par no implica necesariamente una mejor estimación global, ya que fue calculado sobre un conjunto reducido de inliers.

La Figura 4 muestra las correspondencias aceptadas por RANSAC en verde y las descartadas como outliers en rojo. Visualmente, se observa que los pares de *UdeSA* tienen una mayor proporción de correspondencias aceptadas, lo cual coincide con los porcentajes de inliers obtenidos.




Figura 4: Inliers (verde) y outliers (rojo) detectados por RANSAC. Arriba se muestran los pares 0 $\rightarrow$ 1 y abajo los pares 2 $\rightarrow$ 1; a la izquierda, *cuadro*, y a la derecha, *UdeSA*.

Panorámica final

Con las homografías finales de RANSAC se construyeron las panorámicas de ambos conjuntos provistos por la cátedra. En *UdeSA*, donde el edificio funciona como estructura dominante y las homografías tuvieron una alta proporción de inliers, la unión resultó visualmente más limpia. Las costuras no se perciben de forma tan marcada, lo cual es consistente con que gran parte de la escena se aproxima a un mismo plano o se encuentra suficientemente lejos de la cámara.

En *cuadro*, en cambio, se observan algunas desalineaciones en la mesa, el borde inferior y ciertas zonas fuera de la pintura. Esto coincide con lo esperado: la homografía fue estimada principalmente a partir del plano del cuadro, por lo que no necesariamente describe correctamente otros objetos ubicados en planos distintos. Aun así, el cuadro en sí quedó bien alineado.



Figura 5: Panorámicas finales obtenidas para los conjuntos provistos por la cátedra: *cuadro* (izq.) y *UdeSA* (der.).

Imágenes propias

Finalmente, se aplicó el mismo pipeline sobre tres conjuntos propios tomados en la universidad: un ascensor, la biblioteca y la cafetería (pecera). En estos casos se aplicó directamente el criterio combinado elegido previamente. La cantidad de matches obtenidos fue 118 y 130 para *ascensor*, 95 y 96 para *biblioteca*, y 136 y 83 para *pecera*, considerando los pares $0 \rightarrow 1$ y $2 \rightarrow 1$ respectivamente.

Los resultados de RANSAC fueron distintos entre escenas, como se resume en Tabla 2. El conjunto *pecera* obtuvo el mejor ajuste, con 100.0 % y 98.8 % de inliers, y errores de reproyección de 0.677 y 0.872 px. Esto sugiere que las correspondencias fueron muy consistentes con una misma transformación proyectiva.

El conjunto *ascensor* presentó un resultado intermedio, con 94.1 % y 99.2 % de inliers. En cambio, *biblioteca* fue el caso más débil, con 68.4 % y 70.8 % de inliers. Esto es esperable, ya que la escena contiene mayor profundidad y varios planos distintos, lo cual dificulta que una única homografía explique correctamente toda la imagen.

Conjunto y par	Matches	Inliers	Error reproyección
Ascensor $0 \rightarrow 1$	118	111 (94.1 %)	1.812 px
Ascensor $2 \rightarrow 1$	130	129 (99.2 %)	1.911 px
Biblioteca $0 \rightarrow 1$	95	65 (68.4 %)	1.705 px
Biblioteca $2 \rightarrow 1$	96	68 (70.8 %)	2.124 px
Pecera $0 \rightarrow 1$	136	136 (100.0 %)	0.677 px
Pecera $2 \rightarrow 1$	83	82 (98.8 %)	0.872 px

Cuadro 2: Resultados de matching combinado y RANSAC para los conjuntos propios.

Las panorámicas resultantes se muestran en Figura 6. En general, los resultados acompañan las hipótesis geométricas discutidas previamente: las escenas con una estructura más plana o dominante producen una mejor alineación, mientras que las escenas con mayor profundidad presentan más dificultades.



Figura 6: Panorámicas obtenidas para los conjuntos propios: ascensor, biblioteca y pecera.